



Universidade Federal  
de São João del-Rei

# *Elephant Herding Optimization*

Ana Cláudia Machado, Davi dos Reis de Jesus, Gabriel Silva  
Prenassi

Trabalho desenvolvido na disciplina de Algoritmos Bioinspirados

Professora: Carolina Ribeiro Xavier

**São João del-Rei – Maio de 2025**

# Sumário

<b>1</b>	<b><i>Elephant Herding Optimization</i></b>	<b>2</b>
<b>2</b>	<b>Questões de Projeto</b>	<b>2</b>
2.1	Função objetivo . . . . .	2
2.2	Operador de Atualização de Clã . . . . .	2
2.3	Operador de Separação . . . . .	3
<b>3</b>	<b>Implementação</b>	<b>3</b>

# 1 *Elephant Herding Optimization*

Dentre os algoritmos bioinspirados, temos uma série de soluções envolvendo algoritmos de inteligência de enxame, isto é, focados em utilizar o comportamento de um grupo de seres na natureza para otimizar problemas complexos.

O *Elephant Herding Optimization* (EHO) é um algoritmo bioinspirado que considera o comportamento social dos elefantes, os quais vivem em grupos denominados clãs. Cada clã é liderado por uma matriarca, a qual, no algoritmo, é representada pelo indivíduo com melhor *fitness* e sua posição influencia diretamente o comportamento dos demais membros do clã, de modo a promover uma exploração mais direcionada para a melhor solução encontrada até o momento.

Outro comportamento simulado pelo algoritmo é a separação dos machos jovens do restante do clã quando atingem a puberdade. Isso é representado no algoritmo pelo operador de separação, o qual identifica o pior indivíduo de um clã, isto é, com o menor *fitness*, e o reposiciona aleatoriamente no espaço, promovendo maior exploração e evitando ótimos locais.

## 2 Questões de Projeto

As principais questões de projeto envolvem a definição da função objetivo, a representação adotada para as soluções e o uso dos dois operadores do algoritmo: operador de atualização de clã e operador de separação. Para a representação, utilizamos a representação real, conforme proposto no artigo que introduziu o EHO. Essa representação permite uma otimização contínua da posição dos indivíduos no espaço de busca.

### 2.1 Função objetivo

Como função objetivo, adotamos a função de Ackley, Equação 1, a qual é uma função de minimização que possui diversos mínimos locais e o mínimo global em  $x = 0$ . Nesta aplicação temos que  $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$  representa a posição de um elefante no espaço  $n$ -dimensional.

$$f(\mathbf{x}) = -20 \exp \left( -0.2 \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \right) - \exp \left( \frac{1}{n} \sum_{i=1}^n \cos(2\pi x_i) \right) + 20 + e \quad (1)$$

Assim, para um determinado indivíduo, quanto mais próximo de zero for seu *fitness*, melhor será sua solução.

### 2.2 Operador de Atualização de Clã

O operador de atualização de clã promove a mudança da posição de todos os elefantes dentro do espaço  $n$ -dimensional. Nesse sentido, dentro de um clã, todos os elefantes são

influenciados pela posição da matriarca, de modo que suas posições sejam atualizadas considerando a atual posição da matriarca. Para isso, utilizamos a equação

$$x_{new,c_i,j} = x_{c_i,j} + \alpha \cdot (x_{best,c_i} - x_{c_i,j}) \cdot r \quad (2)$$

sendo  $x_{new,c_i,j}$  a nova posição do elefante  $j$  no clã  $c_i$  e  $x_{c_i,j}$  a posição anterior do elefante  $j$  no clã  $c_i$ . Somada a antiga posição do elefante  $j$ , temos a influência exercida pela matriarca do clã  $c_i$ , definida pela multiplicação do fator de influência  $\alpha$ , contido no intervalo  $[0, 1]$ , pela diferença da posição da matriarca,  $x_{best,c_i}$ , para a posição do elefante  $j$ . Por fim, multiplicamos essa influência por um valor aleatório  $r$ , definido no intervalo  $[0, 1]$  seguindo uma distribuição uniforme.

Já a posição da matriarca, não podemos utilizar a Equação 2, haja vista que teríamos  $x_{new,c_i,j} = x_{best,c_i}$ . Assim, definimos uma nova posição para a matriarca com base no centro do *cluster* formado pela seu clã, seguindo a Equação 3. Nesse sentido  $\beta$ , definido no intervalo  $[0, 1]$ , representa o fator de influência do centro do cluster na nova posição da matriarca.

$$x_{new,c_i,j} = \beta \cdot x_{center,c_i} \quad (3)$$

Para definirmos o centro do *cluster*, utilizamos a média do somatório das posições de todos os elefantes do clã, considerando as  $D$  dimensões. Para isso, adotamos a equação 4.

$$x_{center,c_i,d} = \frac{1}{n_{c_i}} \cdot \sum_{j=1}^{n_{c_i}} x_{c_i,j,d} \quad (4)$$

## 2.3 Operador de Separação

Para simular a partida dos jovens elefantes machos ao atingirem a puberdade, aplicamos o operador de separação, o qual, para o indivíduo com pior *fitness* no grupo promove a aleatorização de sua posição. Isso permite uma busca no espaço de possíveis soluções, de modo que acrescenta diversidade na população e evita soluções com ótimos locais.

A equação 5 descreve a definição da nova posição do pior indivíduo do clã,  $x_{worst,c_i}$ , sendo  $x_{max}$  e  $x_{min}$  respectivamente, os limites superior e inferior da solução. *rand* é a aleatorização da posição, com um valor no intervalo  $[0, 1]$  seguindo uma distribuição uniforme.

$$x_{worst,c_i} = x_{min} + (x_{max} - x_{min} + 1) \cdot rand \quad (5)$$

## 3 Implementação

Para a implementação do EHO, seguimos o passo-a-passo proposto no fluxograma da Figura 1. Em relação aos parâmetros, temos o número de clãs e o número de elefantes

em cada um. No artigo original, é proposto que todos os clãs tenham o mesmo número de indivíduos.

Além disso, é necessário parametrizar o número de gerações, o valor de  $\alpha$  utilizado na Equação 2 e o valor de  $\beta$  aplicado na Equação 4.

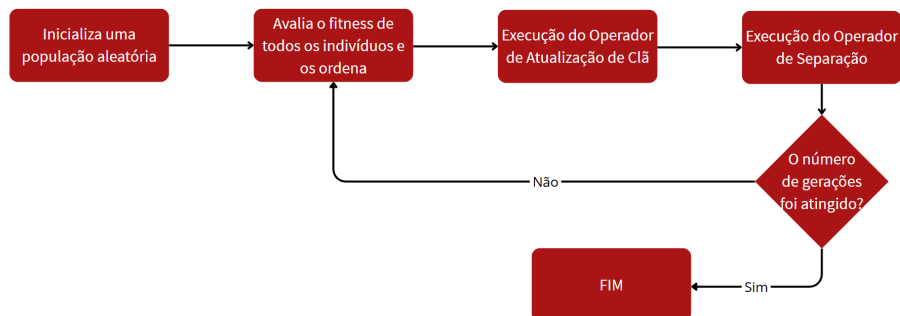


Figura 1: Fluxograma de Execução do EHO

Adotando os mesmos parâmetros proposto nas experimentações do artigo original, temos 50 indivíduos divididos em 5 clãs, isto é, 10 indivíduos compõem cada clã. Definimos  $\alpha$  e  $\beta$  como, respectivamente, 0.5 e 0.1. Ao todo, possuímos 50 gerações e executamos o algoritmo 100 vezes.

Em comparação ao artigo original, o qual obteve como melhor valor  $1.3E - 3$ , obtivemos em nossos experimentos o valor  $1.35E - 3$ .